

Battle Météorage 2026

Gradient Boosting Survival Analysis

Prédiction de fin d'alertes foudre aéroportuaires

Approche complémentaire, suite du rapport Weibull AFT

Plan de la présentation


- 1 Contexte opérationnel
- 2 Les données
- 3 Exploration des données
- 4 Formalisation mathématique
- 5 Modèle non-paramétrique de référence (KM)
- 6 Modèle de Cox et Gradient Boosting Survival
- 7 Construction des features
- 8 Entraînement et calibration des hyperparamètres
- 9 Règle de décision et calibration du seuil
- 10 Évaluation interne et choix de θ
- 11 Protocole et résultats du jury
- 12 Mise en perspective
- 13 Conclusion
- 14 Références

Le problème : règle Météorage actuelle

Règle en production

Une alerte foudre est levée **30 min après le dernier éclair nuage-sol** dans un rayon de 20 km autour de l'aéroport.

Chaque nouvel éclair **remet le compteur à zéro**.



Conséquence opérationnelle

Aéroport fermé tant que des éclairs surviennent, et 30 min de plus après le dernier, **même si l'orage est déjà terminé**.

Coût : immobilisation des opérations sol, retards passagers.

Objectif du projet

Réduire la durée d'attente sous la contrainte **risque** $< 2\%$ qu'un éclair < 3 km survienne après la levée.

Les données fournies par Météorage

Source

Une ligne = **un éclair nuage-sol (CG)** détecté dans un rayon de 20 km autour d'un aéroport.

5 aéroports : Ajaccio, Bastia, Biarritz, Nantes, Pise.

Volumes

Période	Éclairs CG	Alertes
Train 2016-2020	41 509	~2 200
Test 2021-2022	15 090	~800
Jury 2023-2025	80 186	1 352

Colonnes clés




Colonne	Description
date	Horodatage UTC de l'éclair
dist	Distance à l'aéroport (km)
amplitude	Courant de décharge (kA, signé)
icloud	Booléen : éclair intra-nuage (écarté)
airport_alert_id	ID unique de l'alerte en cours
airport	Aéroport concerné

Choix méthodologique

On ne garde **que les CG** (les intra-nuage icloud=True ne sont pas considérés dangereux pour les opérations sol).

Exploration : où et quand frappent les éclairs ?

Distribution des éclairs CG dans les données d'entraînement



Aéroport

Pise (13 483) $\gg$ Nantes (2 678).
Ratio $5\times$.
 $\Rightarrow$ feature `airport_enc`.

Saison



Pic juillet-août.
 $> 60\%$ des éclairs sur 3 mois.
 $\Rightarrow$ feature `doy_sin/cos`.

Heure

Pic 12-15h UTC.
Convection diurne.
 $\Rightarrow$ feature `h_sin/cos`.

Exploration : durée et intensité des orages

Durée et intensité des alertes — données train



Durée d'orage = premier CG → dernier CG

Médiane durée orage	38 min
Q75 durée	60 min
Médiane nb éclairs	3
Q75 nb éclairs	9

Constat

Distribution **très asymétrique** : moitié des orages < 40 min, 3 éclairs. La règle des 30 min ajoute donc une attente quasi égale à la durée moyenne d'un orage.

Synthèse de l'exploration : opportunité d'optimisation

Trois constats forts ressortent des données

- ❶ **Hétérogénéité spatiale** entre aéroports (ratio $5\times$ entre Pise et Nantes) $\Rightarrow$ un modèle doit conditionner sur l'aéroport.
- ❷ **Périodicités fortes** (saison, heure du jour) $\Rightarrow$ encodage cyclique nécessaire pour les arbres de décision.
- ❸ **Alertes courtes en majorité** (médiane 38 min, 3 éclairs) $\Rightarrow$ la règle 30 min impose souvent une attente injustifiée.

Conclusion de l'exploration

Il existe une **marge d'optimisation réelle** : un modèle qui exploite ces régularités peut prédire la fin d'orage plus tôt, sans compromis sur la sécurité, dès lors qu'on quantifie l'incertitude.

$\Rightarrow$ Cadre statistique adapté : **l'analyse de survie**, qui modélise la durée jusqu'à un événement avec censure.

Variable cible T_i

Pour chaque éclair i : T_i = délai (min) jusqu'au prochain CG de la même alerte.

Censure à droite : si l'alerte se ferme avant un nouvel éclair, on sait seulement que $T_i \geq 30$ min. $\delta_i \in \{0, 1\}$: indicateur d'événement (1 = observé, 0 = censuré).

Vérification empirique (train)

95,4 % événements observés, **4,6 %** censurés. La censure existe et doit être traitée correctement.

Hypothèses du modèle

H1. La censure est **non-informative** : la fermeture de l'alerte est indépendante du temps de survie résiduel.

H2. Les éclairs d'une même alerte sont traités comme des observations conditionnellement indépendantes, étant donné le contexte x_i (features).

H3. Le processus est **stationnaire conditionnellement** : le risque à un instant donné ne dépend que de x_i , pas du temps absolu.

H4. (Cox PH) Les covariables ont un effet **multiplicatif** sur le risque instantané.

Fonctions clés en analyse de survie

Trois quantités équivalentes

Fonction de survie : $S(t) = \mathbb{P}(T > t)$, $S(0) = 1$, $S(\infty) = 0$.


Fonction de hasard (risque instantané) :

$$\lambda(t) = \lim_{dt \rightarrow 0} \frac{\mathbb{P}(t \leq T < t + dt \mid T \geq t)}{dt}.$$

Hasard cumulé : $\Lambda(t) = \int_0^t \lambda(u) du$, et $S(t) = e^{-\Lambda(t)}$.

Quantité d'intérêt

Conditionné aux features x_i : $S(30 \mid x_i) = \mathbb{P}(T_i > 30 \mid x_i)$.
Probabilité qu'aucun nouvel éclair ne survienne dans les 30 min suivantes.



Deux $S(t \mid x_i)$ pour des contextes différents.

Premier modèle : Kaplan-Meier global

Estimateur de Kaplan-Meier


$\hat{S}_{KM}(t) = \prod_{T_{(k)} \leq t} (1 - d_k/n_k)$. **Non-paramétrique**, prend en compte la censure.

Résultat sur train

KM produit une **courbe globale unique**. À 2 % de risque : $T_{KM}^* = 28,3$ min, gain = **1,7** min.

Limite $\Rightarrow$ modèle conditionnel

Orage calme et actif reçoivent la **même prédiction**. Il faut $\hat{S}(t \mid x_i)$.



Modèle de Cox à risques proportionnels

Hypothèse fondamentale (PH)

Le risque instantané se factorise :

$$\lambda(t \mid x_i) = \lambda_0(t) \cdot \exp(f(x_i))$$

$\lambda_0(t)$: risque de base (non spécifié), $f(x_i)$: score appris.
Conséquence : ratio des hasards indépendant de t .

Cox linéaire vs Cox non-linéaire

Cox linéaire classique : $f(x_i) = \beta^\top x_i$. Interprétable, mais incapable de capturer interactions non-linéaires (saison $\times$ aéroport, etc.).

Notre choix : $f(x_i)$ appris par un **ensemble d'arbres boostés** (GBS).

Apprentissage de f (vraisemblance partielle)

$$\mathcal{L}(f) = \sum_{i: \delta_i=1} \left[f(x_i) - \log \sum_{j \in R(T_i)} e^{f(x_j)} \right]$$

$R(T_i) = \{j : T_j \geq T_i\}$: ensemble à risque.

Pourquoi le boosting ?

- Capture interactions et non-linéarités.
- Pas d'hypothèse paramétrique sur $\lambda_0(t)$.
- Robuste aux features hétérogènes.
- Régularisation via profondeur et learning rate.

Algorithme : Gradient Boosting Survival

Boucle d'apprentissage (étape $m = 1, \dots, M$)

Initialisation : $f_0(x) = 0$.

Étape 1. Calculer le pseudo-résidu (gradient négatif de la log-vraisemblance partielle évaluée en f_{m-1}) :

$$r_i^{(m)} = - \left. \frac{\partial \mathcal{L}}{\partial f(x_i)} \right|_{f=f_{m-1}}.$$

Étape 2. Ajuster un **arbre de régression** h_m sur les couples $(x_i, r_i^{(m)})$.

Étape 3. Mise à jour avec un pas (learning rate ν) :

$$f_m(x) = f_{m-1}(x) + \nu \cdot h_m(x).$$

Sortie : $\hat{f}(x) = f_M(x)$.

Estimateur de Breslow pour $\hat{\Lambda}_0(t)$

$$\hat{\Lambda}_0(t) = \sum_{T_{(k)} \leq t} \frac{\delta_{(k)}}{\sum_{j \in R(T_{(k)})} e^{\hat{f}(x_j)}}$$

Survie individuelle prédite

Pour un nouvel éclair x_i :

$$\hat{S}(t \mid x_i) = \exp\left(-\hat{\Lambda}_0(t) e^{\hat{f}(x_i)}\right).$$

Implémentation

```
sksurv.ensemble.  
GradientBoostingSurvivalAnalysis
```

Les 13 features construites — un choix justifié

Temporelles cycliques (5)

h = heure + min/60, d = jour de l'année : $h_cos = \cos \frac{2\pi h}{24}$, $h_sin = \sin \frac{2\pi h}{24}$, idem doy_cos , doy_sin , et saison (1-4).

Pourquoi cyclique : arbres ne voient pas que 23h et 1h sont proches.

Cadence / fréquence (2)

- `silence_min` : délai depuis l'éclair précédent.
- `freq_5min` : fréquence glissante sur 5 éclairs.

Signal : cadence qui ralentit $\Rightarrow$ fin d'orage.

Distance à l'aéroport (3)

- `dist_centre` : distance instantanée (km).
 - `dist_avg_5` : moyenne sur 5 derniers éclairs.
 - `dist_min_so_far` : distance min atteinte.
- Signal** : orage qui s'éloigne $\Rightarrow$ alerte qui se termine.

Contexte alerte / aéroport (3)

- `rang` : numéro séquentiel dans l'alerte.
 - `rang_norm` : rang normalisé.
 - `airport_enc` : encodage entier aéroport (v7).
- Signal** : aéroport + position conditionnent la survie.

Procédure

1. Données train 2016-2020 (41 509 éclairs).
2. Standardisation des features (StandardScaler).
3. **GridSearch 3-fold** sur la perte de Cox.
4. Métrique d'arrêt : **C-index** sur validation.

Hyperparamètres optimisés

Paramètre	Valeur	Rôle
n_estimators	50	nb d'arbres M
learning_rate	0,15	pas ν
max_depth	3	complexité arbre
subsample	0,9	stochastique
min_samples_leaf	10	régularisation

Justification des choix

Arbres peu profonds (depth 3) : évite le surapprentissage, les interactions d'ordre élevé sont rares dans ce dataset.

50 arbres, $\nu = 0,15$: couple appris par GridSearch, compromis entre vitesse et régularisation.

Subsample 0,9 : injecte de la variance, améliore la généralisation (cf. Friedman 2002).

Coût de calcul

Entraînement complet : ≈ 2 minutes sur CPU pour les 41 509 éclairs.

De $\hat{S}(t | x_i)$ à la levée d'alerte

Algorithme de décision (seuil θ , ratio $\rho = 0,98$)

Pour chaque éclair x_i de l'alerte en cours :

- 1 Prédire $\hat{S}(t | x_i)$ par le GBS entraîné.
- 2 **Score de confiance** : $\text{conf}(x_i) = \hat{S}(30 | x_i)$ — probabilité estimée qu'aucun nouvel éclair n'arrive avant 30 min.
- 3 Si $\text{conf}(x_i) > \theta$: *éclair confiant* $\Rightarrow$ on calcule l'horizon individuel $\hat{t}_i = \min\{t : \hat{S}(t | x_i) \leq \hat{S}(30 | x_i)/\rho\}$.
- 4 Sinon $\hat{t}_i = +\infty$ (le modèle reste inactif).

Décision globale d'alerte :

$$t_{\text{pred}} = \min_i \hat{t}_i, \quad G = \max(0, t_{\text{règle}} - t_{\text{pred}}).$$

Lecture de la règle

Au moins un éclair doit être suffisamment confiant pour lever. On prend le **minimum** des horizons des éclairs confiants

Métrique principale : le C-index de Harrell

Définition formelle

Le C-index mesure la **concordance** des temps prédits avec les temps observés. Sur les paires comparables (i, j) avec $T_i < T_j$ et $\delta_i = 1$:

$$C = \frac{\#\{(i, j) : \hat{f}(x_i) > \hat{f}(x_j), T_i < T_j, \delta_i = 1\}}{\#\{(i, j) : T_i < T_j, \delta_i = 1\}}$$

$C = 1$: ordonnancement parfait $C = 0,5$: aléatoire.

Pourquoi cette métrique

- Robuste à la censure (paires non-comparables exclues).
- Évalue la **capacité à ordonner**, ce qui est exactement ce dont on a besoin pour appliquer un seuil de décision.
- Ne dépend pas de la calibration absolue de $\hat{S}$.

Résultats validation 2021-2022

Modèle	Train	Test
GBS v6 (12 var.)	0,776	0,741
GBS v7 (13 var.)	0,777	0,742

Interprétation

- Écart train/test $\leq 0,003$: **pas de surapprentissage**.
- $0,742 \gg 0,5$: signal réel capturé.
- $v7 \approx v6$: `airport_enc` améliore surtout la calibration.

Calibration du seuil θ sur validation

Procédure de calibration

On fait varier $\theta \in [0,10; 0,50]$ et on mesure sur le test 2021-2022 :

- le **gain total** (heures économisées),
- le **risque** (% d'éclairs < 3 km manqués).

On choisit le θ qui **maximise le gain** sous la contrainte **risque** $< 2\%$.

Résultats sur test 2021-2022 à $\theta = 0,30$

Métrique	Valeur
Alertes évaluées	~ 800
Gain total	32 h
Gain moyen / alerte	4,5 min
Risque < 3 km	0,18 %

Choix retenu : $\theta = 0,30$

- θ plus bas : modèle plus agressif, risque dépasse 2 %.
- θ plus haut : modèle quasi-inactif, peu de gain.
- $\theta = 0,30$: compromis optimal sur validation.

Validation OK

Risque très en dessous de la limite 2 %, gain non-trivial.

$\Rightarrow$ on **fige** $\theta = 0,30$ et le modèle pour l'évaluation jury sur données 2023-2025 jamais vues.

Protocole d'évaluation du jury (rappel)

Critère officiel Data Battle 2026

Donnée d'évaluation : 80 186 éclairs CG sur 2023-2025, regroupés en 1 352 alertes, *jamaïs vus* pendant l'entraînement.

Pour chaque alerte, le jury compare :

- $t_{\text{règle}}$: moment de levée selon la règle Météorage (dernier CG + 30 min)
- t_{pred} : moment de levée selon notre modèle

Métriques mesurées :

$$\text{Gain} = \sum_{\text{alertes}} \max(0, t_{\text{règle}} - t_{\text{pred}}), \quad \text{Risque} = \frac{\#\{\text{CG} < 3 \text{ km après } t_{\text{pred}}\}}{\#\{\text{CG} < 3 \text{ km au total}\}}.$$

Contrainte stricte : Risque $< 2\%$.

Résultats jury 2023-2025 — performance finale

1 352

alertes évaluées

103,5 h

économisées

0,10 %

risque < 3 km

2 / 1 995

éclairs manqués

Détail par version ($\theta = 0,30$)

Métrique	v6	v7
Gain total	105,1 h	103,5 h
Gain moy./alerte	4,67 min	4,59 min
Risque < 3 km	0,10 %	0,10 %
Alertes actives	~72 %	~72 %

Conformité contrainte sécurité

Risque mesuré 0,10 % contre limite 2 % :

20 fois sous la limite officielle.

Seuls **2 éclairs sur 1 995** (< 3 km) sont arrivés après notre levée.

Robustesse

Performance comparable à validation (test 2021-2022 : 0,18 %).

Pas de dégradation sur les données jury 2023-2025.

GBS vs Weibull AFT (approche binôme)

Critère	Weibull AFT	GBS CoxPH
Type	Paramétrique	Non-paramétrique
Forme imposée sur $S(t)$	$e^{-(t/\lambda(X))^k}$	Aucune
Apprentissage	MLE direct	Boosting gradient
Gain jury	~330 h	103,5 h
Risque < 3 km	0,60 %	0,10 %
Interprétabilité	Haute (β explicite)	Modérée (importances)
Flexibilité	Faible	Haute

Complémentarité

Weibull **maximise le gain brut**, GBS **minimise le risque**. Un modèle hybride (score GBS $\times$ quantile Weibull) est une piste naturelle.

Limites communes

Aucun des deux modèles ne capture la **structure spatiale 2D** de l'orage ni sa direction de déplacement. Un modèle spatio-temporel serait la prochaine étape.

Conclusion

Ce que le GBS apporte

- ✓ Une fonction de survie **individualisée** $\hat{S}(t \mid x_i)$, sans hypothèse paramétrique.
- ✓ **103,5 h économisées** sur jury 2023-2025.
- ✓ **0,10 %** de risque, 20× sous la limite de 2 %.
- ✓ C-index 0,742, écart train/test négligeable.
- ✓ Algorithme transparent et reproductible (scikit-survival).

Perspectives

- Modèle **hybride** : score GBS + quantile Weibull.
- **Direction** de déplacement de l'orage.
- Features v8 : amplitude, tendance.

Message clé

Le GBS prédit, pour **chaque éclair**, la probabilité que l'orage soit terminé. Il lève l'alerte dès qu'un éclair est suffisamment confiant, avec un seuil θ calibré pour rester sous la barre des 2 % de risque.

103,5 h économisées
0,10 % de risque

Méthodologie statistique

- Cox, D.R. (1972). *Regression Models and Life-Tables*. J. R. Stat. Soc. B, 34(2), 187-220.
- Kaplan, E.L. & Meier, P. (1958). *Nonparametric Estimation from Incomplete Observations*. JASA, 53(282), 457-481.
- Breslow, N. (1972). *Contribution to the discussion of Cox (1972)*.
- Harrell, F.E. et al. (1982). *Evaluating the yield of medical tests*. JAMA, 247(18), 2543-2546. (C-index)
- Ridgeway, G. (1999). *The state of boosting*. Comp. Sci. Stat., 31, 172-181. (GBM Cox)
- Friedman, J. (2001). *Greedy Function Approximation : A Gradient Boosting Machine*. Annals of Statistics, 29(5), 1189-1232.
- Pölsterl, S. (2020). *scikit-survival : A Library for Time-to-Event Analysis Built on Top of scikit-learn*. JMLR, 21(212), 1-6.

Logiciels

scikit-survival 0.22 :
GradientBoostingSurvivalAnalysis.
Python 3.11, pandas, NumPy, Matplotlib, Streamlit.

Données

Météorage *Data Battle 2026*.
56 599 éclairs CG, 5 aéroports, 2016-2025.
Variable cible T_i construite par nos soins.

Merci

Questions ?